UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSTGRADO FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS ESCUELA DE POSGRADO



PLAN DE TESIS

Valoración Corporativa Probabilística "Estimación del valor intrínseco de empresas mediante modelos de Machine Learning: una comparación con el método Discounted Cash Flow (DCF)"

PARA OBTENER EL GRADO ACADÉMICO DE MAESTRO EN CIENCIAS CON MENCIÓN EN INTELIGENCIA ARTIFICIAL

ELABORADO POR:

RICARDO VILLENA PRESENTACION

ASESOR:

María Tejada-Begazo

LIMA, PERÚ

2026

DATOS GENERALES

1. Título del plan de tesis

Valoración Corporativa Probabilística “Estimación del valor intrínseco de empresas mediante modelos de Machine Learning: una comparación con el método Discounted Cash Flow (DCF)”

2. Nombre del autor

RICARDO VILLENA PRESENTACION

3. Nombre del asesor o asesores

4. Área involucrada

UNIDAD DE POSTGRADO, FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS (FIIS);
MAESTRÍA EN CIENCIAS CON MENCIÓN EN INTELIGENCIA ARTIFICIAL

5. Lugar o institución donde se desarrolla el proyecto

UNIVERSIDAD NACIONAL DE INGENIERÍA

6. Duración estimada del proyecto en meses (fecha de inicio / fecha de culminación)

01/08/2026 al 15/12/2026

INTRODUCCIÓN

La valoración corporativa constituye el pilar fundamental para la toma de decisiones estratégicas, fusiones, adquisiciones y la gestión de carteras en los mercados de capitales (Ali, 2026; Kaushik & Pandey, 2026). Tradicionalmente, la estimación del valor intrínseco de los activos se ha apoyado en el modelo de Flujo de Caja Descontado (DCF) y en el análisis de múltiplos del mercado (Kaushik & Pandey, 2026; Lu & Zhao, 2025). Sin embargo, la naturaleza lineal, estática y determinista de estos enfoques clásicos presenta severas limitaciones metodológicas para capturar la alta volatilidad, las dependencias temporales complejas y los riesgos de eventos extremos (riesgos de cola) que caracterizan a los mercados bursátiles modernos (Lu & Zhao, 2025)

Ante esta realidad, la irrupción de la inteligencia artificial (IA) y los modelos de aprendizaje automático (ML) representa un cambio de paradigma empírico, ya que estas tecnologías poseen la capacidad computacional para procesar volúmenes masivos de información heterogénea y descubrir patrones no lineales que los métodos estadísticos convencionales ignoran (Blanquet et al., 2025; Caridi et al., 2026). A pesar del rendimiento predictivo superior de los algoritmos de IA como las redes neuronales o los modelos de ensamble basados en árboles su adopción en la práctica financiera enfrenta el reto estructural de la opacidad o el efecto de "caja negra" (Caridi et al., 2026; Pham, 2026). . Este déficit de interpretabilidad exige la implementación de marcos analíticos explicables que traduzcan las predicciones algorítmicas en justificaciones económicas auditables. Por consiguiente, la presente investigación aborda esta brecha desarrollando un modelo avanzado de simulación de valorización que integre el aprendizaje profundo con procesos estocásticos bajo un entorno de incertidumbre macroeconómica.

ÍNDICE

INTRODUCCIÓN II
1. PLANTEAMIENTO DEL PROBLEMA 1
1.1. Planteamiento del problema 1
1.1.1. Identificación y descripción del problema de estudio 1
1.1.2. Antecedentes 1
1.1.3. Formulación del problema 6
1.2. Justificación y alcances 6
1.2.1. Justificación 6
1.2.2. Alcances 6
2. OBJETIVOS DE LA INVESTIGACIÓN 7
2.1. Objetivo General 7
2.2. Objetivos Específicos 7
3. MARCO TEÓRICO 8
3.1. Bases Teóricas 8
3.2. Definición de Términos 9
3.3. Hipótesis y Variables 9
3.3.1. Hipótesis 9
3.3.2. Variables de la Investigación 9
4. DISEÑO METODOLÓGICO 10
4.1. Tipo de Investigación 10
4.2. Nivel de Investigación 10
4.3. Métodos de Trabajo 10
4.4. Población y Muestra 10
4.4.1. Población 10
4.4.2. Muestra 10
4.5. Tipo de Diseño 11
4.6. Técnicas e Instrumentos de Recolección de Datos 11
4.7. Técnicas e Instrumentos de Análisis y Procesamiento de Datos 11
4.8. Etapas de Intervención del Estudio 13
4.9. Justificación de la Metodología 13
5. ADMINISTRACIÓN DEL PLAN DE TESIS 14
5.1. Cronograma 14
5.2. Presupuesto 14
5.3. Financiamiento 14
REFERENCIAS BIBLIOGRÁFICAS 15
ANEXOS 16

CAPÍTULO 1: PLANTEAMIENTO DEL PROBLEMA

1.1. Planteamiento del Problema

1.1.1. Identificación y Descripción del Problema de Estudio

1.1.2. Antecedentes

La investigación realizada por Xing Yang en el año 2025 en Estados Unidos tuvo como objetivo general examinar la reacción del mercado de valores estadounidense ante la irrupción disruptiva de la empresa china DeepSeek y el lanzamiento de su modelo de inteligencia artificial R1. La metodología empleada consistió en un estudio de eventos de tipo empírico y nivel explicativo, con un diseño no experimental y transversal centrado en la captura de retornos anormales acumulados (CAR) en diversas ventanas temporales que oscilaron entre 1 y 9 días alrededor del evento. La población y muestra final estuvo conformada por 5,439 empresas estadounidenses que cotizan activamente en bolsa, dentro de las cuales se identificaron específicamente 93 acciones pertenecientes al sector de IA bajo criterios de palabras clave en sus descripciones de negocio. Como técnicas e instrumentos para la recolección de datos, el autor utilizó la recopilación de precios históricos de acciones e información financiera detallada (Market Cap, ROA, apalancamiento) obtenida de la plataforma Yahoo Finance, empleando el índice S&P 500 como punto de referencia para el cálculo de los retornos. El resultado general reveló que las acciones de IA en EE. UU. reaccionaron de forma significativamente positiva, con coeficientes positivos y significativos al nivel del 1% en todas las regresiones, aunque se observó una reacción negativa en los proveedores de GPU. La conclusión general del estudio es que la competencia global en inteligencia artificial actúa como un catalizador para la innovación y el crecimiento del sector, sugiriendo que los inversores perciben estos avances tecnológicos externos como oportunidades para integrar nuevas tecnologías y mejorar la competitividad de la industria a largo plazo.

La investigación de Baltazar Blanquet, Alves Pereira y Petrov, publicada en el año 2025 en Portugal y Luxemburgo, tuvo como objetivo general desarrollar un marco de trabajo de aprendizaje automático (ML) interpretable para mejorar la precisión en la valoración de empresas, específicamente startups tecnológicos, integrando métricas financieras tradicionales con impulsores de valor intangibles. La metodología se basó en el proceso estándar de la industria para la minería de datos (CRISP-DM), siendo una investigación de tipo empírica con un nivel explicativo y predictivo, bajo un diseño no experimental

que comparó cuatro estructuras distintas de modelos de regresión. La población y muestra consistió en un conjunto de datos de startups tecnológicas nórdicas recolectadas de una base de datos operativa patentada, procesando inicialmente un volumen de 1,308 variables reducidas finalmente a 250 factores clave. Como técnicas e instrumentos para la recolección y análisis de datos, se utilizó un almacén de datos (data warehouse) para garantizar la integridad, aplicando procedimientos de limpieza como la imputación por mediana y el aumento de datos sintéticos mediante ruido gaussiano para mitigar el sobreajuste en muestras pequeñas. El resultado general demostró que el modelo basado en el algoritmo XGBoost, dentro del marco de características de la empresa, fue el más exitoso al alcanzar un coeficiente de determinación (R^2) de 0.997 y un error porcentual absoluto medio (MAPE) de 34.7% (indicado como 34.90% en discusiones previas), logrando una mejora del 30% en precisión respecto a los estándares de la industria. La conclusión general del estudio es que un enfoque de inteligencia artificial híbrida y transparente (mediante técnicas como LIME) permite capturar el capital intelectual y el potencial de innovación que los modelos contables tradicionales ignoran, proporcionando una herramienta robusta y explicable para la toma de decisiones en el capital de riesgo.

La investigación realizada por Tianyi Lu y Yihao Zhao, presentada en el año 2025 en Dalian, China, tuvo como objetivo general desarrollar un modelo de Flujo de Caja Descontado (DCF) mejorado con aprendizaje automático para optimizar la precisión en el pronóstico probabilístico de los flujos de caja futuros. La metodología empleada fue de tipo empírica y nivel predictivo-explicativo, bajo un diseño técnico de arquitectura de redes neuronales recurrentes de tipo Memoria a Largo Corto Plazo (LSTM) diseñada para manejar datos financieros no estacionarios. La población y muestra consistió en los registros financieros históricos de las 500 empresas más grandes de Estados Unidos cotizadas en bolsa (S&P 500) durante el periodo comprendido entre 2010 y 2024. Como técnicas e instrumentos para la recolección y análisis de datos, los autores utilizaron una lista exhaustiva de variables financieras y macroeconómicas procesadas en una arquitectura de dos capas LSTM con 128 y 64 neuronas respectivamente, aplicando el optimizador Adam, funciones de activación tanh/ReLU y técnicas de regularización como Dropout y L2 para mitigar el sobreajuste. El resultado general demostró que el modelo basado en IA logró reducir el error en la predicción de flujos de caja en un 30% en comparación con métodos estadísticos tradicionales como ARIMA y la regresión lineal, permitiendo capturar tendencias no lineales y dependencias temporales

complejas. La conclusión general del estudio es que la integración de redes neuronales LSTM en el marco del DCF disminuye la subjetividad del analista humano y proporciona una herramienta de valoración dinámica significativamente más robusta y precisa para el mercado de valores.

La investigación de Ruling Zhang, Zengrui Tian, Killian J. McCarthy, Xiao Wang y Kun Zhang, publicada en el año 2023 en China, tuvo como objetivo general desarrollar un esquema de aprendizaje automático integrado para predecir la valoración de empresas emprendedoras y asistir a los inversores de capital de riesgo en etapas tempranas. La metodología empleada fue de tipo empírica con un nivel predictivo y explicativo, bajo un diseño técnico de red neuronal profunda optimizada mediante un algoritmo de evolución diferencial y el método de estimación de momento adaptativo (Adam-ENN). La población y muestra consistió en empresas emprendedoras de China, utilizando un conjunto de datos representativo extraído de las bases Thomson Reuters Eikon y Orbis Patent. Como técnicas e instrumentos para la recolección de datos, los autores capturaron variables financieras, de redes sociales de inversores y de patentes, analizando su impacto mediante el método de derivadas parciales y gráficos de dependencia parcial (PDP) para eliminar la opacidad del modelo. El resultado general reveló que el modelo propuesto superó significativamente a los métodos de referencia (Mínimos Cuadrados, Regresión Ridge y Random Forest) en términos de coeficiente de determinación () y error cuadrático medio (RMSE), identificando que el tamaño del sindicato de inversión y el modelo de negocio son los predictores más críticos. La conclusión general del estudio determina que el uso de redes neuronales mejoradas con algoritmos evolutivos permite capturar relaciones no lineales complejas entre el capital social de los inversores y el valor de la firma, proporcionando una herramienta de valoración robusta y transparente para entornos de alta incertidumbre en mercados emergentes.

La investigación de Thuy Tu Pham, publicada en el año 2026 en Ho Chi Minh City, Vietnam, tuvo como objetivo general investigar cómo la incertidumbre de la información global afecta la valoración de las acciones inmobiliarias en los mercados emergentes. La metodología empleada fue de tipo empírica y nivel predictivo-explicativo, bajo un diseño técnico basado en un flujo de trabajo de aprendizaje automático (ML) que integra la teoría del comportamiento financiero con modelos no lineales integrados. La población y muestra consistió en un conjunto de datos de panel de 28 empresas inmobiliarias vietnamitas cotizadas en las bolsas de valores de Ho Chi

Minh (HOSE) y Hanoi (HNX). Como técnicas e instrumentos para la recolección y análisis de datos, el autor utilizó registros mensuales desde enero de 2013 hasta junio de 2024, incorporando fundamentales de la firma, controles macroeconómicos y cuatro índices de incertidumbre global (ESGUI, GPR, WUI y WSI), procesados mediante algoritmos optimizados con Particle Swarm Optimization (PSO) e interpretados con técnicas de IA explicable como SHAP y LIME. El resultado general reveló que el modelo XGBoost fue el más exitoso al alcanzar un coeficiente de determinación (R^2) de 0.962, identificando que el tamaño de la firma y el valor contable son los impulsores de valoración más influyentes, mientras que la incertidumbre mundial (WUI) mostró un patrón de forma de U invertida dependiente del tamaño. La conclusión general del estudio es que las características propias de la empresa dominan consistentemente los resultados de valoración, pero los impactos de la incertidumbre global son no lineales y condicionales al tamaño de la firma, lo que genera una respuesta de "fuga hacia la calidad" hacia las empresas más grandes en periodos de alta ambigüedad macroeconómica

La investigación realizada por Andrea Caridi, Marco Giovannini y Lorenzo Ricciardi Celsi en el año 2026 en Italia (Roma y Milán), tuvo como objetivo general proponer un marco de trabajo para el "Value Investing" asistido por inteligencia artificial que integre la extracción automatizada de datos, el modelado de valoración, la explicabilidad y la supervisión humana (Human-in-the-Loop) en una arquitectura de soporte a la decisión unificada. La metodología empleada fue de tipo aplicada y nivel descriptivo-explicativo, bajo un diseño de estudio de caso centrado en la validación técnica de un flujo de trabajo operativo mediante la plataforma Rivanna AI. La población y muestra estuvo conformada por tres grandes empresas estadounidenses del sector de bebidas cotizadas en bolsa: The Coca-Cola Company, PepsiCo y Keurig Dr Pepper. Como técnicas e instrumentos para la recolección y análisis de datos, los autores utilizaron el procesamiento de reportes públicos de la SEC (10-K, 10-Q y 8-K), transcripciones de llamadas de resultados y estados financieros, aplicando prompteo estructurado con restricciones de esquema para la extracción de indicadores clave de desempeño (KPIs) y el modelado de Flujo de Caja Descontado (DCF). El resultado general reveló que el flujo de trabajo asistido por IA redujo el tiempo de análisis de un rango manual de 25–40 horas a tan solo 8–12 horas, lo que representa un ahorro de tiempo del 68.8%, logrando además una precisión de coincidencia exacta del 87.5% en la extracción de datos financieros críticos. La conclusión general del estudio determina que la

inteligencia artificial funciona como un acelerador del razonamiento gobernado que desplaza el rol del analista desde el procesamiento manual de información hacia la verificación, adjudicación e interpretación estratégica, garantizando la fiabilidad mediante compuertas de validación humana

La investigación realizada por Roberto Moro Visconti en el año 2024 en Milán, Italia, tuvo como objetivo general investigar el impacto de las redes multicapa mejoradas con inteligencia artificial en la valoración de empresas FinTech mediante la introducción de un modelo escalable basado en "Nodos Cópula". La metodología empleada fue de tipo teórica-aplicada y nivel descriptivo-predictivo, bajo un diseño de red multicapa que integra la teoría de redes con procesos de decisión impulsados por IA. La población y muestra se basó en un marco conceptual validado mediante un conjunto de datos representativo y simulado para establecer las bases empíricas del modelo en el sector financiero tecnológico. Como técnicas e instrumentos para la recolección y análisis de datos, el autor utilizó el modelado matemático de Nodos Cópula para sincronizar capas de riesgo, innovación y eficiencia, aplicando además un análisis de regresión para evaluar el impacto de índices de adopción de IA y digitalización sobre el valor de la firma. El resultado general reveló que el índice de adopción de IA presenta un coeficiente positivo y altamente significativo () sobre la valoración, señalando que la eficiencia operativa es el catalizador más crítico para el incremento del valor de mercado. La conclusión general del estudio determina que la integración estratégica de la IA a través de todas las capas operativas es fundamental para optimizar la valoración de las FinTech, lo que requiere adaptar los métodos tradicionales para capturar adecuadamente las eficiencias y el potencial predictivo generado por estas tecnologías

La investigación realizada por Michael Akinola Aruwaji y Matthys J. Swanepoel en el año 2025 en cinco mercados emergentes africanos (Sudáfrica, Nigeria, Egipto, Kenia y Marruecos), tuvo como objetivo general examinar el impacto de los informes Ambientales, Sociales y de Gobernanza (ESG) integrados con inteligencia artificial en la valoración de las empresas. La metodología empleada fue de tipo empírica y nivel predictivo-explicativo, bajo un diseño longitudinal y multimodal que integró la econometría de datos de panel con algoritmos avanzados de aprendizaje automático. La población y muestra consistió en 120 empresas cotizadas de sectores no financieros (manufactura, energía, telecomunicaciones, entre otros), generando un total de 1,200 observaciones de año-empresa durante el periodo 2018-2024. Como técnicas e instrumentos para la recolección y procesamiento de datos, los autores utilizaron el

Procesamiento de Lenguaje Natural (NLP) mediante bibliotecas de Python para extraer índices de sentimiento, claridad y complejidad lingüística de reportes anuales y de sostenibilidad, aplicando además modelos de regresión de efectos fijos combinados con algoritmos de XGBoost y Random Forest para capturar relaciones no lineales. El resultado general reveló que las empresas que adoptan informes ESG integrados con IA exhiben un efecto positivo y significativo en su valoración (= 0.102, p < 0.01), destacando que el algoritmo XGBoost superó a las técnicas convencionales al lograr un coeficiente de determinación () de 0.68. La conclusión general del estudio determina que el uso de herramientas de IA en la divulgación de sostenibilidad no es solo una medida de cumplimiento, sino un diferenciador estratégico que actúa como una señal creíble de transparencia e innovación, lo que reduce la asimetría de información y se traduce directamente en una mayor valoración de mercado en economías emergentes.

1.1.3. Formulación del Problema

¿De qué manera la implementación de un modelo de Flujo de Caja Descontado (DCF) mejorado con aprendizaje automático (redes LSTM) y simulación de Monte Carlo optimiza la precisión predictiva de la valorización y la evaluación de riesgos de cola en empresas que listan en la bolsa de valores bajo escenarios de alta incertidumbre

Problemas Específicos:

1. ¿Cuál es el nivel de mejora en el pronóstico de las trayectorias de los flujos de caja futuros al aplicar redes neuronales recurrentes (LSTM) en comparación con los enfoques deterministas tradicionales?
2. ¿Cómo impactan de manera no lineal los umbrales críticos de las políticas financieras internas, específicamente la estructura de capital (apalancamiento) y las tenencias de efectivo, en la creación de valor intrínseco de la firma?
3. ¿En qué medida la incertidumbre de la información global y macroeconómica influye de forma asimétrica en el precio de las acciones bursátiles, condicionada a características como el tamaño y resiliencia de la empresa?,.
4. ¿De qué forma la integración de técnicas de Inteligencia Artificial Explicable (XAI) dentro de un marco operativo de supervisión humana (*Human-in-the-Loop*) garantiza la transparencia, trazabilidad y gobernanza de las valoraciones propuestas por el modelo?,.

1.2. Justificación y Alcances

1.2.1. Justificación

Justificación Teórica: La investigación se justifica teóricamente al cubrir una brecha fundamental en la literatura de las finanzas corporativas contemporáneas: la superación de los supuestos estáticos y lineales que limitan a los modelos de valoración tradicionales como el Flujo de Caja Descontado (DCF),. El estudio enriquece la teoría del Value Investing al integrar postulados de las finanzas conductuales y la incertidumbre de Knight (Knightian uncertainty), demostrando cómo los choques de información globales y las políticas contables interactúan de forma no lineal para determinar los precios de los activos. De esta forma, se construye un puente teórico entre los fundamentos económicos de la firma y el aprendizaje computacional profundo.

Justificación Práctica: Desde el ámbito pragmático y operativo, el entorno bursátil exige herramientas que reduzcan la alta subjetividad, los sesgos cognitivos del analista y los cuellos de botella operacionales generados por la ingente cantidad de información financiera. La investigación propone un sistema de soporte a la decisión asistido por IA que transforma el esfuerzo manual de procesamiento en validación estratégica. Está empíricamente demostrado que el uso de arquitecturas de IA gobernadas reduce los tiempos de análisis financiero de un rango de 25-40 horas a tan solo 8-12 horas (un ahorro superior al 65%), al tiempo que previene fallos humanos en la extracción de datos. Además, provee al inversor de rangos probabilísticos de valor intrínseco e intervalos de confianza, mejorando la gestión de riesgos extremos (riesgos de cola).

Justificación Metodológica: Metodológicamente, este trabajo valida la integración de un ecosistema analítico multimodal que fusiona redes neuronales de memoria a largo corto plazo (LSTM) diseñadas para series temporales financieras ruidosas, simulaciones estocásticas de Monte Carlo para medir la volatilidad futura, y métodos avanzados de IA explicable (XAI) como los Valores de Shapley (SHAP) y LIME. Esta integración desmitifica el fenómeno de "caja negra" propio del aprendizaje automático, permitiendo cuantificar con precisión y transparencia la contribución de cada ratio contable y variable macroeconómica a la valoración final, sentando un precedente robusto para futuras investigaciones econométricas

1.2.2. Alcances

Alcance Temático: El estudio se circunscribe en las áreas de finanzas corporativas, valoración de activos bursátiles (modelado avanzado de DCF) e inteligencia artificial aplicada (aprendizaje profundo, modelos de ensamble y XAI). No aborda el análisis especulativo de corto plazo (*day trading*), sino que se enfoca en la estimación del valor intrínseco fundamental a largo plazo.

Alcance Poblacional y Espacial: La investigación se centrará en el universo de grandes y medianas empresas no financieras que cotizan activamente en la bolsa de valores de referencia. El sector financiero y bancario es deliberadamente excluido de la muestra debido a que sus estrictas regulaciones operativas y divergentes estructuras de capital distorsionarían las métricas de valoración del modelo estándar.

Alcance Temporal: Se analizarán series temporales financieras utilizando un enfoque longitudinal bajo un mecanismo de ventana deslizante, lo cual requerirá el procesamiento de datos históricos, abarcando típicamente estados financieros consolidados e indicadores macroeconómicos globales de un periodo amplio (ej. de 10 a 15 años recientes) para capturar adecuadamente los ciclos económicos, caídas de mercado y periodos de incertidumbre,

Alcance Operativo: El alcance del desarrollo tecnológico está enmarcado dentro del paradigma de supervisión humana (*Human-in-the-Loop*), lo que significa que el modelo no se diseña como un agente de *trading* autónomo, sino como un acelerador y sistema de soporte de decisiones que requiere la validación experta humana para adjudicar y emitir las valoraciones definitivas

CAPÍTULO 2: OBJETIVOS DE LA INVESTIGACIÓN

2.1. Objetivo General

A partir de los fundamentos teóricos expuestos, se establece como objetivo general desarrollar y validar un modelo de simulación probabilística para la valorización dinámica de empresas que listan en la bolsa de valores, integrando la estructura del Flujo de Caja Descontado (DCF) con arquitecturas avanzadas de aprendizaje automático e inteligencia artificial explicable para optimizar la precisión predictiva frente a escenarios de alta incertidumbre y volatilidad.

2.2. Objetivos Específicos

OE1. Pronosticar las trayectorias de los flujos de caja futuros y derivar métricas de riesgos de cola (eventos atípicos extremos) mediante la aplicación conjunta de Redes Neuronales Recurrentes (LSTM) y simulaciones estocásticas de Monte Carlo.

OE2: Analizar y cuantificar los efectos no lineales y los umbrales críticos que ejercen las políticas financieras internas, específicamente la estructura de capital (apalancamiento) y las tenencias de efectivo, sobre la creación de valor intrínseco de la firma.

OE3: Determinar el impacto moderador que tiene la incertidumbre de la información global (evaluada a través de índices de riesgo geopolítico y sentimiento mediático) en los precios de las acciones, evaluando sus efectos asimétricos condicionados al tamaño y resiliencia de la empresa.

OE4: Implementar técnicas de explicabilidad algorítmica (tales como SHAP y dependencias parciales) dentro de un marco operativo de supervisión humana (Human-in-the-Loop), garantizando la transparencia, trazabilidad interpretativa y gobernanza sobre los resultados de valoración propuestos por el modelo de inteligencia artificial.

CAPÍTULO 3: MARCO TEÓRICO

3.1. Bases Teóricas

El soporte conceptual de este estudio se estructura sobre la convergencia de teorías financieras clásicas y los recientes postulados de la analítica de datos aplicada a las inversiones (Value Investing). En primer lugar, la investigación se fundamenta en las Teorías de la Estructura de Capital y la Liquidez Corporativa, destacando la Teoría del Intercambio (Trade-Off Theory) y la Teoría de la Jerarquía de Preferencias (Pecking Order Theory) (Ali, 2026). Estos enfoques postulan que el apalancamiento financiero y las reservas de efectivo impactan materialmente la valoración de la firma bajo una dinámica compleja y no lineal; si bien niveles moderados de deuda proporcionan escudos fiscales que incrementan el valor, superar un umbral crítico de endeudamiento desencadena costos por dificultades financieras que erosionan el valor de mercado (Ali, 2026)

En segundo lugar, el estudio incorpora los axiomas de la Teoría de las Finanzas Conductuales y la Incertidumbre de Knight (Knightian Uncertainty), la cual establece una clara distinción entre el riesgo histórico cuantificable y la ambigüedad incalculable generada por shocks globales de información, tales como crisis geopolíticas o pandemias (Pham, 2026). Bajo este marco, la alta incertidumbre macroeconómica provoca respuestas asimétricas y sesgos cognitivos en los inversores, originando el fenómeno conocido como "fuga hacia la calidad" (flight to quality), donde el tamaño de la firma y los fundamentos sólidos actúan como un refugio conductual ante la volatilidad del mercado (Pham, 2026).

En tercer lugar, el modelo se cimienta metodológicamente en la integración de la Inteligencia Artificial Explicable (XAI) y la Gobernanza Asistida por Humanos (Human-in-the-Loop). Las plataformas modernas de apoyo a las decisiones financieras demuestran que la IA no debe operar como un agente autónomo, sino como un amplificador cognitivo probabilístico (Caridi et al., 2026). Bajo este enfoque, técnicas de explicabilidad como los Valores de Shapley (SHAP) y los métodos LIME permiten cuantificar la contribución marginal de cada variable predictiva, desglosando la "caja negra" del algoritmo y asegurando que las estimaciones de valor intrínseco cumplan con los rigurosos estándares de trazabilidad y responsabilidad fiduciaria que exige el mercado de valores (Caridi et al., 2026; Pham, 2026).

Finalmente, la literatura en redes multicapa y tecnología financiera complementa este marco postulando que la sincronización de la eficiencia operativa y la adopción digital (mediante nodos cópula de IA) actúa como un catalizador directo que incrementa la confianza de los inversores y optimiza la capitalización de mercado de las organizaciones (Moro Visconti, 2024)

3.2. Definición de Términos

3.3. Hipótesis y Variables

3.3.1. Hipótesis

Hipótesis de la Investigación En estricta correspondencia con el planteamiento del problema, las bases teóricas y los objetivos formulados, la investigación somete a comprobación empírica las siguientes hipótesis:

Hipótesis 1 (H1): El modelo de valoración híbrido que integra el aprendizaje automático (redes LSTM) con la simulación de Monte Carlo proporciona un rango de valoración probabilístico significativamente más preciso y evalúa de manera superior los riesgos de cola en comparación con los enfoques deterministas tradicionales.

Hipótesis 2 (H2): La incorporación de métricas basadas en políticas contables, como la estructura de capital (ratio de apalancamiento) y las reservas corporativas de efectivo, dentro de un modelo algorítmico avanzado incrementa significativamente su capacidad para predecir el valor de la firma al lograr capturar umbrales de crecimiento no lineales.

Hipótesis 3 (H3): La incertidumbre de la información a nivel global ejerce un impacto no lineal en la valoración de las empresas que está intrínsecamente condicionado a la escala de la firma, produciendo un patrón asimétrico en el cual los inversores buscan refugio trasladando su preferencia hacia empresas de gran capitalización en tiempos de alta ambigüedad macroeconómica.

Hipótesis 4 (H4): La optimización de la eficiencia operativa impulsada por la inteligencia artificial ejerce un efecto positivo y directo sobre la valoración bursátil de la empresa, relación que se consolida y valida analíticamente al integrar marcos de gobernanza explicables (Human-in-the-Loop) que reducen las fallas de extracción de datos y aumentan la confiabilidad percibida por los participantes del mercado.

.

3.3.2. Variables de la Investigación

CAPÍTULO 4: DISEÑO METODOLÓGICO

4.1. Tipo de Investigación

La presente investigación se desarrolla bajo un paradigma de enfoque cuantitativo, fundamentado en la recopilación, procesamiento y análisis matemático de grandes y complejos volúmenes de datos financieros históricos y series temporales para descubrir patrones ocultos y proyectar valoraciones bursátiles. El estudio se clasifica como una investigación de tipo aplicada y empírica, ya que su propósito central trasciende la mera formulación teórica para enfocarse en la resolución de un problema práctico y de alta relevancia en los mercados de capitales: la valoración precisa y dinámica de empresas mediante la implementación de herramientas tecnológicas de vanguardia validadas con datos reales.

4.2. Nivel de Investigación

En este sentido, el nivel o alcance de la investigación es dual, siendo simultáneamente predictivo y explicativo. Por un lado, posee un rigor predictivo al utilizar arquitecturas de aprendizaje automático para pronosticar los flujos de caja futuros y calcular el valor intrínseco de las acciones; por otro lado, adopta una postura explicativa al integrar técnicas de inteligencia artificial interpretable que permiten comprender, cuantificar y aislar el impacto de variables específicas —como el apalancamiento o las reservas de efectivo— en el resultado final de la valoración.

4.3. Métodos de Trabajo

4.4. Población y Muestra

4.4.1. Población

La población objeto de estudio está constituida por el universo de empresas de gran capitalización que cotizan activamente en la bolsa de valores durante un horizonte temporal prolongado, excluyendo deliberadamente a las corporaciones del sector financiero o bancario debido a la naturaleza divergente y altamente regulada de sus estructuras de capital.

4.4.2. Muestra

A partir de esta población, se extrae una muestra representativa mediante un muestreo no probabilístico por conveniencia, seleccionando aquellas entidades que dispongan de información contable continua, completa y auditada. Con el objetivo de entrenar los

modelos algorítmicos evitando el grave problema metodológico de la fuga de datos o filtración temporal (data leakage), el conjunto de la muestra se divide cronológicamente en tres subconjuntos estrictos: un setenta por ciento de los datos se destina al entrenamiento de la inteligencia artificial, un quince por ciento se utiliza para la validación y ajuste de los hiperparámetros, y el quince por ciento restante se reserva como un conjunto de pruebas ciego para evaluar el rendimiento final.

4.5. Tipo de Diseño

Para sostener esta estructura, se emplea un diseño de investigación no experimental, longitudinal y de simulación probabilística. Es no experimental debido a que las variables independientes, conformadas por datos macroeconómicos y ratios contables, no son manipuladas por el investigador, sino observadas retrospectivamente en su entorno natural del mercado. Su carácter longitudinal radica en el análisis del comportamiento financiero de las organizaciones a través de múltiples periodos bajo un mecanismo de ventana temporal deslizante, mientras que el componente de simulación permite proyectar escenarios futuros sometidos a altos niveles de incertidumbre y volatilidad.

4.6. Técnicas e Instrumentos de Recolección de Datos

La técnica principal para la recolección de esta información se apoya en la minería de datos (data mining) y la extracción automatizada, operando a través de algoritmos e interfaces de programación de aplicaciones (APIs) conectadas a bases de datos financieras de prestigio global que actúan como el instrumento de recolección primario.

4.7. Técnicas e Instrumentos de Análisis y Procesamiento de Datos

Una vez recolectada la información, el procedimiento de tratamiento de datos resulta fundamental para la viabilidad del estudio. Para garantizar la integridad y estabilidad de los algoritmos, el preprocesamiento sigue un rigor metodológico exhaustivo que inicia con la imputación de valores nulos o faltantes mediante la mediana, y continúa con la aplicación de la winsorización en los percentiles extremos del 1% y 99% para mitigar el efecto distorsionador de los valores atípicos u outliers en el mercado (Ali, 2026). Asimismo, se procede con la estandarización o normalización de todas las características numéricas utilizando transformaciones de tipo Z-score y, para contrarrestar el riesgo de sobreajuste en muestras pequeñas o dispersas, se pueden incorporar técnicas de aumento de datos sintéticos mediante la adición de ruido

gaussiano (Blanquet et al., 2025). Este meticuloso tratamiento prepara el terreno para la fase de análisis de datos, cuyo motor predictivo principal se basa en redes neuronales recurrentes de Memoria a Largo Corto Plazo (LSTM), una arquitectura de aprendizaje profundo diseñada específicamente para modelar datos financieros no estacionarios, ruidosos y con complejas dependencias temporales que escapan a la capacidad de las regresiones lineales tradicionales (Lu & Zhao, 2025).

De manera complementaria, el análisis de los datos trasciende el uso de un solo algoritmo mediante la implementación de un ensamble heterogéneo avanzado denominado Super Learner, el cual apila las predicciones de modelos de base robustos, como los árboles de decisión extremadamente aleatorizados (Extra Trees) y la potenciación del gradiente extremo (XGBoost), utilizando una regresión lineal como meta-aprendiz para encontrar la ponderación predictiva óptima (Ali, 2026). Estas proyecciones algorítmicas no se presentan como un valor estático único, sino que se integran dentro de un marco de Simulación de Monte Carlo impulsado por procesos de difusión de saltos, lo que permite generar miles de trayectorias de flujos de caja y del costo dinámico de capital (WACC) para construir una campana de distribución probabilística del valor de la empresa, capturando así los riesgos de eventos extremos en la bolsa (Lu & Zhao, 2025). La validez de estos modelos híbridos se garantiza rigurosamente a través de técnicas de validación cruzada de k-pliegues (k-fold cross-validation) rotando iterativamente los datos de entrenamiento y prueba (Blanquet et al., 2025). Por su parte, la confiabilidad se evalúa y cuantifica midiendo empíricamente las tasas de error mediante el Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE) y la capacidad explicativa del Coeficiente de Determinación (R^2).

Finalmente, para dotar al estudio de transparencia y cumplir con los más altos estándares éticos y operativos, el modelo implementa soluciones contra el fenómeno de "caja negra" intrínseco a la inteligencia artificial mediante técnicas de explicabilidad algorítmica (Explainable AI). Se utilizan los Valores de Shapley (SHAP) y los gráficos de dependencia parcial para desglosar y visualizar la contribución exacta y no lineal que cada variable financiera aporta a la valoración final de la empresa (Ali, 2026). Todo este entramado analítico opera bajo un estricto marco de gobernanza algorítmica caracterizado por la supervisión humana (Human-in-the-Loop), el cual impone compuertas de validación donde el analista financiero interviene para verificar la trazabilidad de los datos extraídos hasta sus fuentes documentales originales, adjudicar discrepancias y validar las proyecciones (Caridi et al., 2026). Este enfoque ético asegura

que la inteligencia artificial funcione como un poderoso acelerador del razonamiento estadístico, manteniendo intacta la responsabilidad humana, la auditabilidad de las decisiones y la confiabilidad del modelo como herramienta de soporte para las inversiones bursátiles.

4.8. Etapas de Intervención del Estudio

La implementación del modelo de valoración híbrido propuesto se estructurará a través de cuatro etapas de intervención secuenciales, diseñadas a partir de una arquitectura de tres capas que integra la extracción de datos, el modelado financiero y la supervisión humana (Caridi et al., 2026):

Fase 1: Preparación y Arquitectura de Datos (Capa de Datos): Esta etapa inicial comprende la extracción automatizada de registros financieros históricos y variables macroeconómicas mediante interfaces de programación de aplicaciones (APIs). Posteriormente, se ejecuta el preprocesamiento de los datos, el cual incluye la imputación de valores faltantes mediante la mediana, la estandarización (Z-score) y la winsorización en los percentiles 5% y 95% para mitigar el efecto de valores atípicos extremos del mercado (Ali, 2026). La base de datos resultante se divide cronológicamente en subconjuntos de entrenamiento (80%) y validación/prueba (20%) para evitar la filtración de datos temporales (Ali, 2026; Lu & Zhao, 2025).

Fase 2: Entrenamiento del Modelo Predictivo (Capa de Modelado): En esta fase se entrenan los algoritmos de aprendizaje automático para el pronóstico de los flujos de caja futuros. Se implementan arquitecturas de aprendizaje profundo como las Redes Neuronales Recurrentes de Memoria a Largo Corto Plazo (LSTM) de múltiples capas, optimizadas con el algoritmo Adam y regularización Dropout (Lu & Zhao, 2025). Paralelamente, se desarrolla un ensamble avanzado tipo *Super Learner* que combina algoritmos base (como Extra Trees y XGBoost) utilizando una regresión lineal como meta-aprendiz para encontrar la ponderación predictiva óptima de las ratios de estructura de capital y liquidez corporativa (Ali, 2026).

Fase 3: Simulación Estocástica e Integración DCF: Las predicciones base generadas por la IA se integran en un marco de Simulación de Monte Carlo impulsado por ecuaciones diferenciales discretizadas mediante el método de Euler-Maruyama (Lu & Zhao, 2025). En esta etapa se generan miles de trayectorias (ej. 1,000 simulaciones por empresa) que proyectan los flujos de efectivo sobre un horizonte temporal de 5 años. Se aplica un cálculo dinámico del Costo Promedio Ponderado de Capital (WACC),

actualizando las Betas de la industria y la estructura de capital iterativamente para obtener una campana de distribución probabilística del valor empresarial (Lu & Zhao, 2025).

Fase 4: Explicabilidad y Gobernanza (Capa de Supervisión): La etapa final se centra en "abrir la caja negra" de las predicciones algorítmicas mediante técnicas de Inteligencia Artificial Explicable (XAI). Se implementan los Valores de Shapley (SHAP) y métodos LIME para cuantificar la contribución marginal de variables específicas, como la incertidumbre global (WUI) o el tamaño de la firma, en cada predicción de valor (Pham, 2026). Simultáneamente, se ejecutan las compuertas de validación de supervisión humana (Human-in-the-Loop o HITL), donde los analistas financieros verifican la trazabilidad de los datos, resuelven discrepancias cruzadas y validan la consistencia de los supuestos macroeconómicos antes de emitir los rangos de valoración finales (Caridi et al., 2026).

4.9. Justificación de la Metodología

La elección de una metodología cuantitativa, predictiva y de simulación probabilística asistida por inteligencia artificial se justifica teórica y pragmáticamente ante las profundas limitaciones estructurales de los métodos de valoración tradicionales en mercados volátiles. Clásicamente, el modelo de Flujo de Caja Descontado (DCF) se apoya en proyecciones lineales, tasas de crecimiento estáticas (como el modelo de Gordon) y una alta subjetividad del analista, lo cual resulta insuficiente e inadecuado para capturar las relaciones no lineales, el ruido de las series temporales financieras y los riesgos de cola provocados por escenarios de alta incertidumbre global (Lu & Zhao, 2025). Al incorporar redes neuronales LSTM y ensambles *Super Learner*, la metodología garantiza una capacidad computacional superior para procesar grandes volúmenes de datos históricos, detectar umbrales críticos de rentabilidad en la estructura de capital y pronosticar flujos de efectivo con márgenes de error significativamente menores (Ali, 2026; Lu & Zhao, 2025).

Adicionalmente, la justificación de integrar la Simulación de Monte Carlo radica en su poder para transmutar predicciones puntuales deterministas en evaluaciones de riesgo dinámicas. En lugar de arrojar un único precio objetivo, el modelo entrega intervalos de confianza y distribuciones estadísticas que reflejan el impacto de eventos extremos ("Cisnes Negros") y choques macroeconómicos asimétricos, dotando al inversor de una

herramienta robusta para la medición del Valor en Riesgo (VaR) y la gestión de carteras bajo ambigüedad (Lu & Zhao, 2025; Pham, 2026).

Por último, la adopción de una arquitectura multimodal que incluye Inteligencia Artificial Explicable (XAI) y Gobernanza Asistida por Humanos (*Human-in-the-Loop*) se justifica por la exigencia fiduciaria y regulatoria propia de los mercados de capitales. Los sistemas puramente automatizados (caja negra) carecen de auditabilidad, lo que introduce un alto "riesgo de modelo" inaceptable para la toma de decisiones estratégicas (Caridi et al., 2026). Al emplear SHAP y LIME para desglosar la importancia de las variables (Pham, 2026) y al establecer compuertas donde el analista guía los algoritmos mediante prompteo estructurado y valida las fuentes (Caridi et al., 2026), esta metodología asegura que el sistema funcione no como un tomador de decisiones autónomo y opaco, sino como un poderoso acelerador del razonamiento financiero, el cual preserva la responsabilidad humana, la trazabilidad de la evidencia empírica y los principios fundamentales del *Value Investing*.

CAPÍTULO 5: ADMINISTRACIÓN DEL PLAN DE TESIS

5.1. Cronograma

Tabla *Cronograma de ejecución del proyecto de investigación*

Actividades	Semana															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Adaptar al formato de proyecto de trabajo de investigación	X															
Recopilar información		X														
Analizar datos			X	X												
Discusión de resultados					X	X	X	X								
Conclusiones y recomendaciones									X							
Elaborar artículo										X	X	X				
Postular a revista científica indexada													X	X	X	
Sustentar el proyecto de trabajo de investigación																X

5.2. Presupuesto

Recursos humanos				
Datos de la investigador		Valor/und S/	Duración del proyecto/mes	Monto total
Villena Presentacion Ricardo		-	-	-
			Subtotal	0.00
Servicio de tercero				
Descripción del servicio	Und ref.	Valor/und S/	Cuantía	Monto total S/.
	Und	-	-	-
	Und	-		-
			Subtotal	0
Equipos y bienes duraderos				
Descripción del bien	Und ref.	Valor/und en S/	Cuantía	Monto total S/.
Laptop	Und	9,000.00	1	9,000.00
		Subtotal		9,000.00
Pasajes y viáticos				
Detalle	Und ref.	Valor/und S/	Cuantía	Monto total S/.
-	-	-	-	-
		Subtotal		0
Materiales e insumos				
Detalle del material o insumo	Und ref.	Valor/und en S/	Cuantía	Monto total S/.
Internet	Mes	45.00	4	180.00
Luz	Mes	80.00	4	320.00
		Subtotal		500.00
		Total, recurso monetario		9,500

3.1. Financiamiento

Tabla 3 *Financiamiento de recursos del* ***proyecto*** *de investigación*

Recursos		Monto		Entidad financiadora
No monetario	Recursos humanos	S/.3,000		financiada por el investigador
	Servicio de tercero	S/. 125		
	Equipo y bien duradero	S/. 4,300		
	Pasaje y viático	S/. 260		
	Material e insumo	S/.9		
	Subtotal	S/. 7,694		
Monetario	Recursos humanos	S/.0.00		financiada por el investigador
	Servicio de tercero	S/.0.00		
	Equipo y bien duradero	S/.1,000		
	Pasaje y viático	S/.0.00		
	Material e insumo	S/.500		
	Subtotal	S/.1,500		

5.3. Financiamiento

Propio

REFERENCIAS BIBLIOGRÁFICAS

Ali, G. M. (2026). Firm valuation using accounting-based capital structure and cash holdings: An explainable machine learning approach. *International Journal of Data and Network Science, 10*, 577–596. https://doi.org/10.5267/j.ijdns.2026.2.001

Aruwaji, M. A., & Swanepoel, M. J. (2025). The Impact of AI-Integrated ESG Reporting on Firm Valuation in Emerging Markets: A Multimodal Analytical Approach. *Journal of Risk and Financial Management, 18*(12), 675. https://doi.org/10.3390/jrfm18120675

Blanquet, L. B., Pereira, M. A., & Petrov, S. (2025). An interpretable machine learning framework for explaining company valuation. *Decision Analytics Journal, 16*, 100611.

Caridi, A., Giovannini, M., & Ricciardi Celsi, L. (2026). AI-Assisted Value Investing: A Human-in-the-Loop Framework for Prompt-Guided Financial Analysis and Decision Support. *Electronics, 15*(1155).

Kaushik, R., & Pandey, A. (2026). Valuation Multiples Through a Thematic Lens: Unveiling Trends, Mapping Developments, and Forging New Research Pathways. *Accounting, Finance & Governance Review, 36*. https://doi.org/10.52399/001c.160329

Lee, H., & Park, J. (2026). Organizational Culture and Financial Performance: A Machine Learning Approach. *Asia-Pacific Journal of Financial Studies, 55*, 116–154. https://doi.org/10.1111/ajfs.70027

Lu, T., & Zhao, Y. (2025). The Machine Learning-Enhanced DCF Model and Probabilistic Cash Flow Forecasting. En *2025 International Conference on Management Science and Computer Engineering (MSCE 2025)*. Association for Computing Machinery. https://doi.org/10.1145/3760023.3760045

Moro Visconti, R. (2024). Artificial Intelligence-Driven FinTech Valuation: A Scalable Multilayer Network Approach. *FinTech, 3*, 479–495. https://doi.org/10.3390/fintech3030026

Pham, T. T. (2026). Global Information Uncertainty and Real Estate Stock Valuation in Emerging Markets: An Integrated Behavioral-Theoretical and Machine Learning Framework. *Real Estate Management and Valuation, 34*(1), 66–83.

Yang, X. (2025). Market reactions to the launch of the DeepSeek R1 model. *Finance Research Letters, 80*, 107447. https://doi.org/10.1016/j.frl.2025.107447

Zhang, R., Tian, Z., McCarthy, K. J., Wang, X., & Zhang, K. (2023). Application of machine learning techniques to predict entrepreneurial firm valuation. *Journal of Forecasting, 42*(2), 402–417. https://doi.org/10.1002/for.2912

ANEXOS